

Detección de Fraude Financiero mediante Aprendizaje Automático

JUAN MOSQUERA,¹, MARIA MOSQUERA,², y MICHAEL MOLINA,²

(juan.mosquerap@udea.edu.co)

(mpaula.mosquera@udea.edu.co)

(michael.molina@udea.edu.co)

^{1,2}*Departamento de Ingeniería de Sistemas, Facultad de Ingeniería, Universidad de Antioquia, Medellín, Colombia*

Este trabajo presenta el desarrollo de un sistema de detección de fraude financiero basado en técnicas de aprendizaje automático supervisado, utilizando el conjunto de datos IEEE-CIS Fraud Detection compuesto por 155,504 registros y 434 variables. La metodología implementada abarcó cinco etapas: preprocesamiento y análisis exploratorio de datos, auditoría y selección de características, entrenamiento y evaluación de modelos, optimización de hiperparámetros y reducción de dimensionalidad. Se evaluaron seis modelos de clasificación: Regresión Logística, Árbol de Decisión, Random Forest, XGBoost, Red Neuronal Multicapa (MLP) y Máquina de Vectores de Soporte (SVC). El proceso de selección de características redujo el espacio de 633 a 239 variables mediante eliminación por baja varianza, alta correlación y ranking consolidado de importancia. El modelo XGBoost optimizado mediante búsqueda aleatoria de hiperparámetros con validación cruzada estratificada obtuvo el mejor desempeño: ROC-AUC de 0.9500, PR-AUC de 0.7943, precisión de 0.89 y recall de 0.67 para la clase de fraude. La exploración de técnicas de reducción de dimensionalidad (PCA con 110 componentes y UMAP con 2 componentes) demostró que estas degradaron el rendimiento del modelo, confirmando que las 239 características seleccionadas representan el espacio óptimo para la detección de fraude en este dataset.

Palabras clave: Detección de fraude financiero, XGBoost, aprendizaje supervisado, desbalance de clases, selección de características

1 INTRODUCCIÓN

La digitalización de los servicios financieros ha transformado la manera en que las personas y las organizaciones realizan transacciones económicas. Actualmente, millones de operaciones son procesadas diariamente a través de plataformas electrónicas, permitiendo una mayor rapidez, accesibilidad y cobertura de los servicios financieros. Sin embargo, este crecimiento también ha incrementado la exposición de las instituciones a actividades fraudulentas cada vez más sofisticadas, generando pérdidas económicas significativas y afectando la confianza de los usuarios en los sistemas de pago digitales [1].

El fraude financiero constituye uno de los principales desafíos para bancos, entidades productoras de tarjetas y plataformas de comercio electrónico. Según reportes recientes de la industria, las pérdidas ocasionadas por fraude continúan aumentando a nivel mundial debido al crecimiento de las transacciones digitales y a la evolución constante de las estrategias utilizadas por los

ciberdelincuentes [2]. Adicionalmente, estudios realizados en América Latina evidencian que el impacto económico del fraude va más allá de las pérdidas directas, incluyendo costos asociados a investigaciones, recuperación de fondos, afectación reputacional y disminución de la confianza de los clientes [3].

La detección temprana de transacciones fraudulentas representa un problema complejo debido a varios factores. En primer lugar, los conjuntos de datos financieros suelen contener millones de registros y cientos de variables asociadas a información transaccional y de identidad. En segundo lugar, los eventos fraudulentos representan únicamente una pequeña proporción del total de observaciones, generando conjuntos de datos altamente desbalanceados. Adicionalmente, los patrones de fraude evolucionan de forma constante, dificultando la construcción de reglas estáticas capaces de detectar todas las modalidades existentes [4].

Ante este escenario, las técnicas de aprendizaje automático han demostrado ser herramientas efectivas para la identificación automática de patrones complejos y relaciones no lineales dentro de grandes volúmenes de información. Estos modelos permiten construir sistemas predictivos capaces de aprender a partir de datos históricos y

adaptarse a nuevas formas de fraude con mayor flexibilidad que los enfoques tradicionales basados en reglas [5, 6].

En este trabajo se aborda el problema de detección de fraude financiero mediante la aplicación de técnicas de aprendizaje automático sobre el conjunto de datos IEEE-CIS Fraud Detection, publicado por Kaggle como parte de una competencia internacional enfocada en el desarrollo de modelos predictivos para la identificación de transacciones fraudulentas [7]. A partir de este conjunto de datos se desarrolló un proceso experimental que incluyó la preparación de los datos, auditoría y reducción de características, selección de variables relevantes y entrenamiento de múltiples algoritmos de clasificación supervisada.

La metodología implementada contempló una evaluación comparativa entre diferentes modelos de Machine Learning, incluyendo Regresión Logística, Árbol de Decisión, Random Forest, Máquina de Vectores de Soporte (SVC), Redes Neuronales Multicapa (MLP) y XGBoost. Posteriormente, el modelo con mejor desempeño fue sometido a un proceso de optimización de hiperparámetros mediante validación cruzada estratificada, con el fin de maximizar su capacidad para identificar transacciones fraudulentas. Adicionalmente, se analizó el impacto de técnicas de reducción de dimensionalidad lineales y no lineales, específicamente PCA y UMAP, evaluando su influencia sobre el desempeño predictivo del modelo seleccionado.

El objetivo principal de esta investigación consiste en analizar el comportamiento de diferentes algoritmos de aprendizaje supervisado para la detección de fraude financiero y determinar cuál de ellos ofrece el mejor desempeño sobre el conjunto de datos estudiado. Para ello se emplean métricas apropiadas para problemas altamente desbalanceados, tales como ROC-AUC y PR-AUC, así como medidas complementarias de precisión, sensibilidad y F1-Score. Asimismo, se busca establecer si la reducción de dimensionalidad permite disminuir la complejidad del problema sin afectar significativamente la capacidad de generalización de los modelos entrenados.

2 DESCRIPCIÓN DEL PROBLEMA

El fraude financiero representa una de las principales amenazas para las entidades bancarias, plataformas de comercio electrónico y sistemas de pago digitales. El crecimiento acelerado de las transacciones electrónicas ha incrementado la necesidad de desarrollar mecanismos automáticos capaces de identificar comportamientos sospechosos en tiempo real y reducir las pérdidas económicas asociadas a actividades fraudulentas. Sin embargo, la detección de fraude constituye un problema complejo debido al elevado volumen de información generado diariamente, la evolución constante de los patrones utilizados por los defraudadores y el fuerte desbalance existente entre las transacciones legítimas y fraudulentas [4].

En este contexto, las técnicas de aprendizaje automático permiten construir modelos capaces de identificar relaciones complejas entre múltiples variables y detectar pa-

trones difíciles de identificar mediante reglas tradicionales. La capacidad de estos modelos para aprender directamente a partir de los datos históricos los convierte en una alternativa adecuada para apoyar los procesos de detección y prevención de fraude financiero [5].

Para el desarrollo del presente trabajo se utilizó el conjunto de datos IEEE-CIS Fraud Detection, publicado por Kaggle como parte de una competencia internacional enfocada en la construcción de modelos predictivos para la detección de fraude [7]. El conjunto de datos utilizado durante la experimentación estuvo conformado por 106.239 registros y 633 variables predictoras, además de la variable objetivo *isFraud*, la cual indica si una transacción corresponde a un evento fraudulento (1) o legítimo (0). Las variables disponibles incluyen información transaccional, características derivadas del comportamiento de compra, variables relacionadas con dispositivos utilizados durante la transacción e información de identidad anonimizada.

Como primera etapa del análisis se realizó una exploración de los datos con el objetivo de comprender su estructura, identificar posibles problemas de calidad y determinar las transformaciones necesarias para el proceso de modelado. El análisis exploratorio permitió identificar la presencia de un fuerte desbalance de clases, donde las transacciones fraudulentas representan una pequeña proporción del total de observaciones. Esta característica es común en problemas reales de detección de fraude y representa uno de los principales desafíos para la construcción de modelos predictivos robustos.

Adicionalmente, se observó la existencia de valores faltantes en múltiples variables del conjunto de datos. Con el fin de garantizar la consistencia de la información utilizada durante el entrenamiento de los modelos, se implementó una estrategia de imputación basada en la mediana para las variables numéricas. Este método fue seleccionado debido a su robustez frente a distribuciones asimétricas y valores extremos, características frecuentemente presentes en conjuntos de datos financieros [8]. Las variables categóricas habían sido previamente transformadas mediante técnicas de codificación numérica durante las etapas iniciales de preprocesamiento, permitiendo su utilización por parte de los algoritmos de aprendizaje supervisado.

Dado el elevado número de variables disponibles, se realizó una auditoría de características con el propósito de reducir redundancia y complejidad computacional. Inicialmente se eliminaron 118 variables con varianza inferior a 0.01 utilizando el método Variance Threshold. Posteriormente, se calculó la matriz de correlación absoluta entre las variables restantes y se eliminaron aquellas que presentaban correlaciones superiores a 0.95, reduciendo el conjunto final a 239 características. Este procedimiento permitió disminuir la multicolinealidad y conservar únicamente las variables con mayor capacidad informativa [9, 10].

Para complementar el análisis de relevancia de las variables, se construyó un ranking consolidado utilizando tres enfoques diferentes: Mutual Information, importancia de variables obtenida mediante Random Forest e importancia derivada de XGBoost. Este procedimiento permitió identificar las características con mayor capacidad discriminativa

respecto a la variable objetivo y evaluar diferentes subconjuntos de variables durante las etapas posteriores de entrenamiento.

Desde la perspectiva de Machine Learning, el problema fue abordado como una tarea de clasificación supervisada binaria. Esta configuración fue seleccionada debido a que se dispone de ejemplos previamente etiquetados mediante la variable *isFraud*, permitiendo entrenar modelos capaces de aprender patrones asociados a ambas clases. La naturaleza binaria del problema y la disponibilidad de datos históricos etiquetados justifican la utilización de algoritmos de clasificación supervisada como Regresión Logística, Árboles de Decisión, Random Forest, Máquinas de Vectores de Soporte, Redes Neuronales y XGBoost, los cuales fueron evaluados comparativamente durante el desarrollo del proyecto.

Finalmente, con el objetivo de garantizar una evaluación imparcial del desempeño de los modelos, el conjunto de datos fue dividido utilizando una estrategia estratificada en un 80% para entrenamiento y un 20% para prueba. La estratificación permitió preservar la distribución original de la variable objetivo en ambos conjuntos, condición fundamental para obtener estimaciones confiables del desempeño en problemas altamente desbalanceados [4].

3 ESTADO DEL ARTE

La detección de fraude financiero ha sido abordada ampliamente mediante técnicas de aprendizaje automático debido al alto impacto económico de este problema y a la dificultad de identificar manualmente patrones fraudulentos en grandes volúmenes de transacciones. Además, este tipo de problema suele presentar un fuerte desbalance de clases, dado que las transacciones fraudulentas representan una proporción reducida frente al total de operaciones legítimas. Por esta razón, diversos trabajos han propuesto modelos de clasificación supervisada y estrategias de evaluación orientadas a mejorar la detección de la clase minoritaria.

Carmona y Londoño desarrollaron un estudio de detección de fraude financiero utilizando un conjunto de datos transaccional obtenido de Kaggle. El problema fue formulado como una tarea de clasificación supervisada binaria, donde la variable objetivo indicaba si una transacción era fraudulenta o legítima. Las autoras evaluaron modelos como Regresión Logística, Random Forest, Naive Bayes y Redes Neuronales, utilizando una partición de entrenamiento y prueba, además de estrategias de sobremuestreo mediante SMOTE para tratar el desbalance de clases. Las métricas utilizadas fueron exactitud, precisión, sensibilidad, F1-score y curva ROC. Sus resultados mostraron que la Regresión Logística obtuvo el mejor desempeño general para su caso de estudio, especialmente por su alta sensibilidad en la detección de fraudes [11].

Dal Pozzolo et al. estudiaron el problema de clasificación desbalanceada aplicado a fraude con tarjetas de crédito. El trabajo se enmarca dentro del paradigma de aprendizaje supervisado y analiza el efecto del submuestreo sobre la calibración de probabilidades en mod-

elos de clasificación. Los autores utilizaron estrategias de validación experimental sobre datos altamente desbalanceados y evaluaron el desempeño mediante métricas asociadas a la detección de la clase positiva. Este estudio resulta relevante porque evidencia que, en problemas de fraude, la distribución desigual de las clases puede afectar tanto la capacidad predictiva como la interpretación probabilística de los modelos, por lo que se requieren métricas y estrategias de validación adecuadas [4].

En un trabajo enfocado directamente en el conjunto de datos IEEE-CIS Fraud Detection, se propuso una estrategia basada en modelos de ensamble como CatBoost, XGBoost y LightGBM. El problema fue abordado como una tarea de clasificación supervisada binaria, utilizando información transaccional e identidad anonimizada para identificar operaciones fraudulentas. Los autores emplearon técnicas de aprendizaje basadas en gradient boosting y una combinación de modelos mediante ensamble, reportando que este tipo de algoritmos presenta una alta capacidad para capturar relaciones no lineales y mejorar el desempeño frente a clasificadores tradicionales [12].

Almalki y Masud propusieron un enfoque de detección de fraude financiero basado en ensambles tipo stacking e inteligencia artificial explicable. El estudio utilizó el conjunto de datos IEEE-CIS Fraud Detection, compuesto por más de 590.000 registros transaccionales. Los autores combinaron modelos como XGBoost, LightGBM y CatBoost, y utilizaron técnicas de explicabilidad como SHAP, LIME, PDP y Permutation Feature Importance para interpretar las decisiones del modelo. La validación se realizó mediante métricas de clasificación como Accuracy y ROC-AUC. El modelo propuesto alcanzó una exactitud cercana al 99% y un ROC-AUC de 0.99, evidenciando el potencial de los métodos de ensamble para problemas de fraude financiero de alta dimensionalidad [13].

En conjunto, los trabajos revisados muestran que la detección de fraude financiero se aborda principalmente como un problema de clasificación supervisada binaria. Asimismo, se observa una tendencia hacia el uso de modelos basados en ensambles de árboles, especialmente XGBoost, LightGBM y CatBoost, debido a su capacidad para modelar relaciones complejas en datos tabulares. También se identifica la importancia de utilizar métricas apropiadas para datos desbalanceados, tales como sensibilidad, F1-score, ROC-AUC y PR-AUC, ya que la exactitud puede resultar engañosa cuando la clase fraudulenta representa una proporción reducida del total de observaciones. Estos antecedentes justifican la comparación de múltiples modelos de clasificación y la selección de XGBoost como uno de los enfoques principales evaluados en el presente trabajo.

4 ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

4.1 Configuración Experimental

Una vez finalizada la etapa de preparación de datos y selección de características, se procedió al entrenamiento y evaluación de diferentes modelos de aprendizaje super-

visado para la detección de fraude financiero. El conjunto de datos fue dividido mediante una estrategia estratificada, asignando el 80% de las observaciones al conjunto de entrenamiento y el 20% restante al conjunto de prueba. La estratificación permitió conservar la distribución original de la variable objetivo *isFraud* en ambos conjuntos, aspecto fundamental debido al fuerte desbalance presente entre las clases.

Para garantizar la reproducibilidad de los experimentos se utilizó una semilla aleatoria fija (*random state=42*) durante todos los procesos de partición, entrenamiento y validación. Adicionalmente, se empleó validación cruzada estratificada mediante *StratifiedKfold* con cinco particiones durante los procesos de ajuste de hiperparámetros y evaluación de modelos.

Debido a la naturaleza altamente desbalanceada del problema, se implementaron diferentes estrategias para mitigar el sesgo hacia la clase mayoritaria. En los modelos compatibles se utilizaron esquemas de ponderación de clases mediante el parámetro *balanced*, mientras que en XGBoost se empleó el parámetro *scale_pos_weight*. Para algunos algoritmos sensibles al desbalance, como Regresión Logística y Redes Neuronales, también se evaluó el uso de técnicas de sobremuestreo mediante SMOTE dentro de pipelines de entrenamiento.

Los algoritmos evaluados corresponden a diferentes familias de aprendizaje supervisado, con el objetivo de comparar enfoques lineales, no lineales y basados en ensambles. Los modelos seleccionados fueron:

- Regresión Logística (modelo paramétrico).
- Árbol de Decisión (modelo no paramétrico).
- Random Forest (ensamble de árboles).
- Máquina de Vectores de Soporte (SVC).
- Red Neuronal Multicapa (MLPClassifier).
- XGBoost (Gradient Boosting).

Para los modelos sensibles a la escala de las variables se aplicó una transformación mediante *StandardScaler*. Posteriormente se realizó una búsqueda de hiperparámetros utilizando *RandomizedSearchCV* para identificar las configuraciones con mejor desempeño.

Table 1. Hiperparámetros evaluados para cada modelo

Modelo	No. de hiperparámetros evaluados
Regresión Logística	3
Árbol de Decisión	3
Random Forest	3
SVC	3
MLPClassifier	3
XGBoost	6

La Tabla 1 resume la cantidad de hiperparámetros considerados durante el proceso de optimización de cada algoritmo. Para cada modelo se seleccionaron los parámetros más relevantes reportados en la literatura y se evaluaron múltiples configuraciones mediante validación cruzada estratificada.

Para la evaluación del desempeño se utilizaron las métricas ROC-AUC y PR-AUC como medidas principales, debido a su capacidad para evaluar clasificadores en escenarios desbalanceados. Adicionalmente, se calcularon Precision, Recall y F1-Score para la clase fraudulenta.

La métrica ROC-AUC mide la capacidad global del modelo para discriminar entre ambas clases a diferentes umbrales de decisión. Por otra parte, PR-AUC resulta especialmente relevante en problemas de fraude, ya que evalúa simultáneamente la precisión y la sensibilidad sobre la clase minoritaria, proporcionando una medida más representativa del desempeño real del clasificador [4].

4.2 Resultados del Entrenamiento de los Modelos

Una vez definido el conjunto final de 239 características mediante los procesos de selección y auditoría descritos anteriormente, se procedió al entrenamiento y evaluación de los diferentes modelos de aprendizaje automático considerados en el estudio. El objetivo de esta etapa fue identificar el algoritmo con mayor capacidad para detectar transacciones fraudulentas dentro de un escenario caracterizado por un fuerte desbalance entre clases.

La evaluación se realizó sobre el conjunto de prueba utilizando las métricas ROC-AUC, PR-AUC, Precision, Recall y F1-Score para la clase fraudulenta. Debido a la naturaleza del problema, se otorgó especial importancia a la métrica PR-AUC, ya que esta proporciona una evaluación más representativa del desempeño cuando existe una proporción muy reducida de observaciones positivas.

La Tabla 2 presenta el resumen de los resultados obtenidos para todos los modelos evaluados.

Los resultados muestran que XGBoost alcanzó el mejor desempeño general entre todos los modelos evaluados, obteniendo un ROC-AUC de 0.9285 y un PR-AUC de 0.7024. Estos resultados evidencian una elevada capacidad para discriminar entre transacciones legítimas y fraudulentas, superando ampliamente a los demás clasificadores analizados.

Por su parte, MLPClassifier obtuvo el segundo mejor resultado en términos de PR-AUC (0.5371), seguido por Random Forest (0.5174). Aunque ambos modelos lograron identificar patrones relevantes dentro de los datos, ninguno alcanzó la capacidad predictiva observada en XGBoost. Los modelos tradicionales, como Regresión Logística y Árbol de Decisión, presentaron desempeños moderados, mientras que SVC obtuvo los resultados más bajos, reflejando dificultades para modelar adecuadamente la complejidad y dimensionalidad del conjunto de datos.

La Figura 1 complementa los resultados de la Tabla 2, mostrando de forma gráfica los valores de ROC-AUC y PR-AUC obtenidos por cada uno de los modelos evaluados.

Como puede observarse en la Figura 1, XGBoost presenta los mayores valores tanto en ROC-AUC como en PR-AUC. Dado que el objetivo principal del proyecto consiste en detectar correctamente la clase fraudulenta minimizando la generación de falsas alarmas, se seleccionó

Table 2. Comparación de desempeño de los modelos evaluados

Modelo	ROC-AUC	PR-AUC	Precision	Recall	F1
XGBoost	0.9285	0.7024	0.3575	0.7383	0.4817
MLPClassifier	0.8570	0.5371	0.4158	0.5402	0.4699
Random Forest	0.8958	0.5174	0.1949	0.7215	0.3068
Decision Tree	0.8640	0.3810	0.1438	0.7664	0.2421
Logistic Regression	0.8651	0.3532	0.0973	0.7589	0.1725
SVC	0.5472	0.0718	0.0247	0.8804	0.0481




Fig. 1. Comparación del desempeño de los modelos evaluados mediante las métricas ROC-AUC y PR-AUC.

este algoritmo para una etapa posterior de optimización de hiperparámetros.

4.2.1 Optimización de XGBoost

Debido a su desempeño superior durante la fase inicial de evaluación, XGBoost fue seleccionado para un proceso de optimización mediante *RandomizedSearchCV* y validación cruzada estratificada de cinco particiones. Durante esta etapa se exploraron diferentes combinaciones de hiperparámetros asociados al número de árboles, profundidad máxima, tasa de aprendizaje, submuestreo y selección aleatoria de variables.

La Tabla 3 presenta los mejores hiperparámetros obtenidos durante el proceso de optimización.

Table 3. Mejores hiperparámetros obtenidos para XGBoost

Parámetro	Valor óptimo
max_depth	8
learning_rate	0.136
gamma	0.184
colsample_bytree	0.891
n_estimators	49

Los resultados obtenidos demostraron una mejora significativa respecto a la versión inicial del modelo. El valor de ROC-AUC aumentó de 0.9285 a 0.9500, mientras que el

PR-AUC pasó de 0.7024 a 0.7943. Considerando que PR-AUC fue la métrica principal utilizada para la selección del modelo, esta mejora representa un incremento cercano al 13% en la capacidad para identificar transacciones fraudulentas.

Los resultados anteriores evidencian que la optimización de hiperparámetros permitió incrementar la capacidad de generalización del modelo y mejorar el equilibrio entre precisión y sensibilidad para la clase minoritaria. En consecuencia, el modelo XGBoost optimizado fue seleccionado como modelo final para la etapa de evaluación definitiva presentada en la siguiente subsección.

4.2.2 Evaluación del Modelo Final

Una vez finalizado el proceso de optimización de hiperparámetros, el modelo XGBoost fue evaluado sobre el conjunto de prueba independiente con el objetivo de estimar su capacidad de generalización frente a datos no observados durante el entrenamiento.

Los resultados obtenidos muestran un desempeño sobresaliente en todas las métricas analizadas. El modelo alcanzó un valor de ROC-AUC de 0.9500 y un PR-AUC de 0.7943, evidenciando una elevada capacidad para discriminar entre transacciones legítimas y fraudulentas. Para la clase de fraude, el modelo obtuvo una precisión de 0.8903, un recall de 0.6673 y un F1-Score de 0.7628, reflejando

un equilibrio adecuado entre la capacidad de detección y el control de falsas alarmas.

La Figura 2 presenta la matriz de confusión obtenida para el modelo final. Como puede observarse, el clasificador identificó correctamente 20.669 transacciones legítimas y 357 transacciones fraudulentas. Asimismo, únicamente 44 transacciones legítimas fueron clasificadas erróneamente como fraude, mientras que 178 transacciones fraudulentas no fueron detectadas. Estos resultados evidencian una elevada precisión operativa y una capacidad significativa para reducir el número de falsas alertas, aspecto especialmente relevante en sistemas de monitoreo financiero.




Fig. 2. Matriz de confusión obtenida para el modelo XGBoost optimizado.

La Figura 3 muestra la curva ROC obtenida para el modelo final. Se observa que la curva se mantiene considerablemente alejada de la diagonal asociada a un clasificador aleatorio, alcanzando un área bajo la curva (ROC-AUC) de 0.9500. Este resultado confirma la elevada capacidad discriminativa del modelo para diferenciar entre transacciones fraudulentas y legítimas en diferentes umbrales de decisión.

De forma complementaria, la Figura 4 presenta la curva Precision-Recall del modelo optimizado. Esta métrica resulta particularmente relevante en problemas altamente desbalanceados como la detección de fraude, donde la proporción de transacciones fraudulentas es considerablemente menor que la de transacciones legítimas. El área bajo la curva Precision-Recall alcanzó un valor de 0.7943, confirmando la capacidad del modelo para mantener altos niveles de precisión incluso cuando se incrementa la sensibilidad en la detección de fraude.

En conjunto, los resultados obtenidos confirman que XGBoost optimizado constituye la mejor alternativa para el problema analizado. El modelo logró el mejor desempeño entre todos los algoritmos evaluados y presentó el equilibrio más favorable entre precisión, sensibilidad y capacidad de generalización, convirtiéndose en una solución ade-




Fig. 3. Curva ROC del modelo XGBoost optimizado.




Fig. 4. Curva Precision-Recall del modelo XGBoost optimizado.

cuada para escenarios reales de detección de fraude financiero.

5 REDUCCIÓN DE DIMENSIONALIDAD

5.1 Análisis individual de variables

Como punto de partida para la reducción de dimensionalidad, se realizó un análisis individual de cada una de las 633 características del conjunto de datos con el objetivo de identificar variables redundantes, de baja capacidad informativa o altamente correlacionadas con otras. Este análisis se llevó a cabo exclusivamente sobre el conjunto de entrenamiento *X_train* para evitar fuga de información hacia el conjunto de prueba.

En primer lugar, se aplicó el método *VarianceThreshold* con un umbral de 0.01 para identificar y eliminar las características con varianza cercana a cero. Esta técnica permite descartar variables que presentan valores prácticamente constantes en la totalidad de las observaciones y que, por tanto, aportan escasa capacidad discriminativa al modelo

[9]. Como resultado de esta etapa se eliminaron 118 variables, reduciendo el espacio de características de 633 a 515.

Posteriormente, se construyó la matriz de correlación de Pearson en valor absoluto sobre las variables restantes. Se identificaron los pares de características con correlación superior a 0.95 y se eliminó una variable de cada par para reducir la multicolinealidad y la redundancia de información. Este procedimiento es consistente con las recomendaciones de la literatura para el tratamiento de conjuntos de datos de alta dimensionalidad [10]. Como resultado, el conjunto final quedó conformado por 239 características, lo que representa una reducción acumulada del 62.2% respecto al espacio original.

La Tabla 4 resume los resultados obtenidos durante las diferentes etapas de auditoría y depuración de variables.

Table 4. Resumen de la auditoría de características

Etapas	V. eliminadas	V. restantes
Conjunto inicial	—	633
Baja varianza (< 0.01)	118	515
Alta correlación (> 0.95)	276	239

Con el fin de identificar las variables más relevantes para la detección de fraude, se construyó un ranking consolidado combinando tres métodos de selección de características: Información Mutua (*Mutual Information*), importancia de variables derivada de *Random Forest* e importancia derivada de *XGBoost*. Para cada técnica se generó un ranking individual y posteriormente se calculó un ranking promedio (*Combined Rank*) que permitió identificar las variables con mayor capacidad discriminativa respecto a la variable objetivo *isFraud*.

La Figura 5 presenta las veinte variables mejor posicionadas según este ranking consolidado.

Top 20 features by Consolidated Rank									
	Feature	MI_Score	MI_Rank	RF_Importance	RF_Rank	XGB_Importance	XGB_Rank	Combined_Rank	
0	V201	0.034241	1.0	0.046538	1.0	0.253004	1.0	1.000000	
5	V45	0.026863	6.0	0.031751	4.0	0.030218	5.0	5.000000	
6	V198	0.026794	7.0	0.025714	6.0	0.017527	8.0	7.000000	
7	V246	0.026776	8.0	0.017522	11.0	0.003896	40.0	19.666667	
49	V245	0.020066	50.0	0.024285	7.0	0.027697	6.0	21.000000	
46	V148	0.020317	47.0	0.012266	15.0	0.037396	4.0	22.000000	
14	id_17	0.024478	15.0	0.010176	20.0	0.003765	42.0	25.666667	
11	V67	0.025254	12.0	0.005488	47.0	0.008116	20.0	26.333333	
4	V189	0.027063	5.0	0.038923	2.0	0.002274	73.0	26.666667	
34	V87	0.021621	35.0	0.021944	10.0	0.003441	44.0	29.666667	
50	card3	0.019929	51.0	0.009349	22.0	0.009211	17.0	30.000000	
29	V78	0.022356	30.0	0.008622	27.0	0.004198	34.0	30.333333	
18	V247	0.023749	19.0	0.004406	66.0	0.025232	7.0	30.666667	
12	card1	0.024663	13.0	0.007480	33.0	0.002118	77.0	41.000000	
83	ProductCD	0.015795	84.0	0.008921	25.0	0.010732	14.0	41.000000	
47	V157	0.020147	48.0	0.004323	67.0	0.010188	16.0	43.666667	
42	MI_was_null	0.020825	43.0	0.003424	87.0	0.042911	3.0	44.333333	
129	C1	0.008335	130.0	0.032093	3.0	0.011305	13.0	48.666667	
67	V53	0.017503	68.0	0.006678	37.0	0.003338	46.0	50.333333	
19	V123	0.023738	20.0	0.011048	19.0	0.001631	113.0	50.666667	

Fig. 5. Top 20 variables según ranking consolidado de importancia (Mutual Information, Random Forest y XGBoost). Valores menores de *Combined Rank* indican mayor importancia relativa respecto a la variable objetivo *isFraud*.

5.2 Extracción de características lineal: PCA

Una vez definido el conjunto óptimo de 239 características, se exploró la aplicación de técnicas de extracción de características con el objetivo de determinar si era posible reducir aún más la dimensionalidad sin afectar significativamente el desempeño predictivo.

Como primera aproximación se utilizó el Análisis de Componentes Principales (PCA), una técnica lineal ampliamente utilizada para representar conjuntos de datos de alta dimensionalidad mediante combinaciones lineales de las variables originales. Previamente a la aplicación de PCA, las características fueron estandarizadas mediante *StandardScaler* para garantizar que todas las variables contribuyeran de manera homogénea al cálculo de los componentes principales.

Se estableció como criterio de selección la conservación del 95% de la varianza explicada acumulada. Bajo este criterio se obtuvieron 110 componentes principales, lo que representa una reducción del 54% respecto al conjunto original de 239 variables.

La Figura 6 muestra la evolución de la varianza explicada acumulada y el punto de corte correspondiente a los 110 componentes seleccionados.

```

---- APLICANDO PCA ----
Número de componentes seleccionados por PCA: 110
Varianza explicada acumulada por los componentes de PCA: 0.9510
Shape de X_train_pca: (84991, 110)
Shape de X_test_pca: (21248, 110)

```

Fig. 6. Varianza explicada acumulada por número de componentes principales (PCA). La línea vertical indica el punto de corte al 95% de varianza retenida, correspondiente a 110 componentes.

Posteriormente, el modelo XGBoost optimizado fue entrenado y evaluado utilizando las representaciones obtenidas mediante PCA para comparar su desempeño frente al modelo entrenado sobre las 239 características seleccionadas.

5.3 Extracción de características no lineal: UMAP

Como alternativa no lineal se implementó *Uniform Manifold Approximation and Projection* (UMAP), técnica diseñada para preservar tanto la estructura local como la global de los datos en espacios de alta dimensionalidad [6].

Para este experimento se configuró una representación de únicamente dos componentes $n_components = 2$, lo que equivale a una reducción del 99.2% respecto al espacio original. Aunque esta configuración resulta adecuada para tareas de visualización, representa una reducción extremadamente agresiva para un problema de clasificación supervisada.

Una vez obtenidas las nuevas representaciones, el modelo XGBoost optimizado fue entrenado y evaluado utilizando las características generadas por UMAP.

Con el propósito de comparar objetivamente las tres estrategias evaluadas, la Tabla 5 presenta los resultados obtenidos para el modelo XGBoost optimizado con y sin

Table 5. Comparación de desempeño: XGBoost con y sin reducción de dimensionalidad

Estrategia	Variables	Reducción	ROC-AUC	PR-AUC	Precision	Recall	F1
XGBoost Tuned (239 var.)	239	0%	0.9500	0.7943	0.8903	0.6673	0.7628
XGBoost + PCA (110 comp.)	110	54.0%	0.8957	0.5799	0.8300	0.4000	0.5400
XGBoost + UMAP (2 comp.)	2	99.2%	0.7696	0.1860	0.0600	0.6500	0.1100




Fig. 7. Impacto de las técnicas de reducción de dimensionalidad sobre el desempeño del modelo XGBoost.

reducción de dimensionalidad, con PCA y UMAP. La Figura 7 muestra el impacto de las técnicas de reducción de dimensionalidad sobre el desempeño del modelo XGBoost, comparando las métricas ROC-AUC y PR-AUC obtenidas con PCA y UMAP frente al modelo optimizado sin reducción de dimensionalidad.

Los resultados obtenidos evidencian que la aplicación de técnicas de reducción de dimensionalidad degradó el desempeño del modelo XGBoost optimizado en ambos casos. La pérdida de rendimiento es especialmente pronunciada en el escenario UMAP, donde la reducción extrema a 2 componentes elimina prácticamente toda la información discriminativa necesaria para la detección de fraude. En el caso de PCA con 110 componentes, aunque la reducción es más conservadora, la transformación lineal no captura las relaciones no lineales entre variables que resultan fundamentales para este problema.

Estos resultados confirman que las 239 características seleccionadas mediante la auditoría de varianza y correlación representan el espacio óptimo para el problema estudiado, y que la reducción adicional mediante métodos de extracción de características introduce pérdida de información no compensada por la reducción en dimensionalidad [5].

6 DISCUSIÓN Y CONCLUSIONES

Los resultados obtenidos a lo largo de las cinco etapas de la metodología permiten extraer conclusiones relevantes

sobre el desempeño de los modelos de aprendizaje supervisado evaluados y sobre el impacto de las decisiones de preprocesamiento y reducción de dimensionalidad en la capacidad predictiva del sistema de detección de fraude.

En primer lugar, la comparación de los seis algoritmos evaluados en la fase inicial de entrenamiento muestra una superioridad clara de XGBoost sobre los demás enfoques, tanto en términos de ROC-AUC (0.9285) como de PR-AUC (0.7024). Este resultado es consistente con los trabajos reportados en el estado del arte, donde los modelos basados en *gradient boosting* demuestran sistemáticamente mayor capacidad para capturar relaciones no lineales en datos tabulares de alta dimensionalidad [13, 12]. El desempeño del modelo SVC fue notablemente inferior (ROC-AUC: 0.5472, PR-AUC: 0.0718), lo que puede atribuirse a las dificultades inherentes de las máquinas de vectores de soporte para escalar eficientemente en espacios de alta dimensionalidad con fuerte desbalance de clases.

En segundo lugar, la optimización de hiperparámetros de XGBoost mediante *RandomizedSearchCV* con validación cruzada estratificada permitió incrementar el ROC-AUC desde 0.9285 hasta 0.9500 y el PR-AUC desde 0.7024 hasta 0.7943, representando una mejora relativa del 13% sobre la métrica principal. Los hiperparámetros óptimos obtenidos *max_depth=8*, *learning_rate=0.136*, *gamma=0.184*, *colsample_bytree=0.891*, *n_estimators=49* sugieren un modelo con profundidad moderada y regularización controlada, adecuado para el nivel de complejidad del problema. La precisión de 0.89 y el recall de 0.67

para la clase de fraude representan un equilibrio favorable entre la detección de fraudes reales y la minimización de falsas alarmas, aspecto crítico en aplicaciones operativas de monitoreo transaccional.

En tercer lugar, el análisis de reducción de dimensionalidad demostró que la aplicación de PCA y UMAP sobre el conjunto de 239 características seleccionadas degrada el rendimiento del modelo optimizado. Este hallazgo tiene implicaciones metodológicas importantes: en problemas de detección de fraude financiero con datos de alta dimensionalidad y fuerte desbalance, las técnicas de extracción de características no necesariamente mejoran el desempeño, especialmente cuando el conjunto de variables ha sido previamente depurado mediante métodos de selección basados en relevancia discriminativa. La reducción extrema aplicada por UMAP (a 2 componentes) resulta particularmente perjudicial para la tarea de clasificación, ya que esta configuración fue diseñada para visualización y no para preservar la separabilidad entre clases en espacios de muy baja dimensión.

Comparando los resultados con los trabajos del estado del arte, el modelo desarrollado obtiene un desempeño competitivo aunque inferior al reportado por Almalki y Masud (ROC-AUC: 0.99) [13]. Esta diferencia puede explicarse por las distintas estrategias de ensamble utilizadas (stacking de múltiples modelos *gradient boosting*) y por el mayor volumen de datos disponible en dicho trabajo (590.000 registros frente a los 106.239 utilizados en el presente estudio). No obstante, el modelo XGBoost optimizado desarrollado en este trabajo supera ampliamente los resultados obtenidos por enfoques basados en Regresión Logística reportados en trabajos previos sobre el mismo dataset [11], confirmando la adecuación de XGBoost para este tipo de problema.

Los resultados del análisis exploratorio complementan los hallazgos del modelado. La tasa de fraude del 8.71% para la categoría C de *ProductCD* y la mayor prevalencia de fraude en dispositivos móviles (5.45%) identificadas en el análisis bivariado son coherentes con el hecho de que las variables más influyentes en el modelo pertenecen a los bloques Vesta y de comportamiento transaccional, y no al monto de la operación, que demostró ser un predictor marginal.

En conclusión, los resultados obtenidos demuestran que las técnicas de aprendizaje automático constituyen una alternativa eficaz para la detección de fraude financiero en entornos caracterizados por grandes volúmenes de datos, alta dimensionalidad y fuerte desbalance entre clases. Entre los modelos evaluados, XGBoost optimizado mediante búsqueda aleatoria de hiperparámetros y validación cruzada estratificada presentó el mejor desempeño, alcanzando un ROC-AUC de 0.9500 y un PR-AUC de 0.7943 sobre el conjunto de prueba independiente. Estos resultados evidencian la capacidad de los métodos basados en *gradient boosting* para capturar patrones complejos presentes en las transacciones fraudulentas y mantener simultáneamente altos niveles de precisión y capacidad de generalización.

El proceso de selección de características desempeñó un papel fundamental en el desempeño final del sistema. La combinación de eliminación de variables con baja varianza, reducción de variables altamente correlacionadas y selección basada en un ranking consolidado de importancia permitió reducir el conjunto inicial de 633 variables a 239 características relevantes. Esta reducción disminuyó la complejidad computacional del problema y facilitó el entrenamiento de los modelos sin afectar negativamente su capacidad predictiva.

Los experimentos realizados con técnicas de reducción de dimensionalidad mostraron que ni PCA ni UMAP lograron superar el rendimiento obtenido por el modelo entrenado sobre las 239 características seleccionadas. Aunque PCA conservó gran parte de la información presente en los datos, se observó una disminución en las métricas de desempeño, mientras que UMAP produjo una degradación más significativa. Estos resultados sugieren que la selección de características realizada previamente permitió conservar la información discriminativa más relevante para el problema de detección de fraude.

Adicionalmente, el análisis de importancia de variables evidenció que la detección de fraude no depende únicamente de atributos transaccionales simples, sino que requiere incorporar variables de comportamiento y contexto. Las características pertenecientes al bloque Vesta, junto con variables relacionadas con el producto y el dispositivo utilizado en la transacción, mostraron una elevada capacidad discriminativa, resaltando la importancia de este tipo de información en la construcción de sistemas de detección de fraude más robustos.

Finalmente, la comparación con los trabajos revisados en el estado del arte permitió verificar que los resultados obtenidos son competitivos frente a otras soluciones reportadas para el mismo conjunto de datos. Como líneas de trabajo futuro se propone explorar estrategias de ensamble basadas en *stacking* que integren modelos como XGBoost, LightGBM y CatBoost, incorporar técnicas de explicabilidad como SHAP y LIME para facilitar la interpretación de las decisiones del modelo, y evaluar el comportamiento del sistema sobre ventanas temporales deslizantes que permitan capturar la evolución de los patrones de fraude a lo largo del tiempo.

7 REFERENCES

- [1] The Nilson Report, "Payment Card Fraud Losses Worldwide in 2023," Tech. Rep. 11, HSN Consultants, Inc. (2025), issue 1296, January 2025.
- [2] FICO, "Card-Not-Present Fraud Remains a Leading Concern as Payment Systems Evolve," <https://www.fico.com/blogs/card-not-present-fraud-remains-leading-concern-payment-systems-evolve> (2025), accessed: May 24, 2026.
- [3] LexisNexis Risk Solutions, "El verdadero costo del fraude en América Latina," <https://risk.lexisnexis.com/global/es/about-us/press-room/press-release/20240620-true-cost-of-fraud-colombia> (2024).

- [4] A. D. Pozzolo, O. Caelen, R. A. Johnson, and G. Bontempi, “Calibrating probability with undersampling for unbalanced classification,” in *Proc. IEEE Symp. Comput. Intell. Data Mining (CIDM)*, 4, pp. 159–166, Orlando, FL (2015).
- [5] F. Provost and T. Fawcett, *Data Science for Business*, 2 (O’Reilly Media, 2013).
- [6] J. VanderPlas, *Python Data Science Handbook*, 3 (O’Reilly Media, 2016).
- [7] Kaggle, “IEEE-CIS Fraud Detection,” <https://www.kaggle.com/competitions/ieee-fraud-detection/data> (2019), accessed: May 22, 2026.
- [8] R. J. A. Little and D. B. Rubin, *Statistical Analysis with Missing Data*, 9 (Wiley, Hoboken, NJ, 2019), 3rd ed.
- [9] R. Johnson and D. Wichern, *Applied Multivariate Statistical Analysis*, 6 (Pearson Prentice Hall, Upper Saddle River, NJ, 2007), 6th ed.
- [10] J. F. Hair, W. C. Black, B. J. Babin, and R. E. Anderson, *Multivariate Data Analysis*, 7 (Cengage Learning, 2019), 8th ed.
- [11] M. C. Mora and L. M. L. Morales, “Modelos de Machine Learning para la Detección de Fraude Financiero,” (2021).
- [12] ResearchGate, “IEEE-CIS Fraud Detection Based on XGB,” https://www.researchgate.net/publication/378508394_IEEE-CIS_Fraud_Detection_Based_on_XGB (2024), accessed: June 7, 2026.
- [13] F. Almalki and M. Masud, “Financial Fraud Detection Using Explainable AI and Stacking Ensemble Methods,” <https://arxiv.org/abs/2505.10050> (2025), accessed: June 7, 2026.